


Introduction aux Réseaux de Neurones

Fichiers sur

<https://github.com/mkirschpin/CoursPython>

<http://kirschpm.fr/cours/PythonDataScience/>

De la régression linéaire aux neurones




Ici, la somme pondérée des features donne une estimation linéaire de la valeur attendue

Et si on utilisait la régression pour la classification ?

- Au lieu d'une sortie linéaire, je cherche à établir une classification
- **Quelle est la probabilité d'appartenir à une classe cible ?**
- La fonction sigmoïde - $\sigma(z_i)$
- Représente les prédictions selon un point de vue probabiliste
 - Plus grand et positif est z_i , plus probable sera la valeur y_i

$$z_i = (b_1 \times x_{i1}) + (b_2 \times x_{i2}) + \dots + (b_M \times x_{iM}) + b_0$$


Sigmoid Function $p(y_i = 1|x_i) = \sigma(z_i)$



Exemple

$$z_i = (b_1 \times 0.5) + (b_2 \times 0.8) + (b_3 \times 75) + (b_4 \times 1.2) + b_0$$

Sigmoid Function $p(y_i = 1|x_i) = \sigma(z_i)$




features

Cloud Cover	Humidity	Temperature	Air Pressure
0.5	80%	75	1.2

- Les paramètres b indiquent combien les variables sont importantes pour la prédiction


Schéma d'une Régression Logistique



Surprise !!! Ceci est le schéma d'un **neurone artificiel** (perceptron). On a un **réseau d'un neurone** !!


Exemple d'usage pratique

- Exemple : le dataset MNIST
 - Ensemble de chiffres écrits à la main
- Objectif : identifier le chiffre
 - 0 à 9



Mise en route

- Les chiffres sont des images, chaque pixel a une valeur numérique

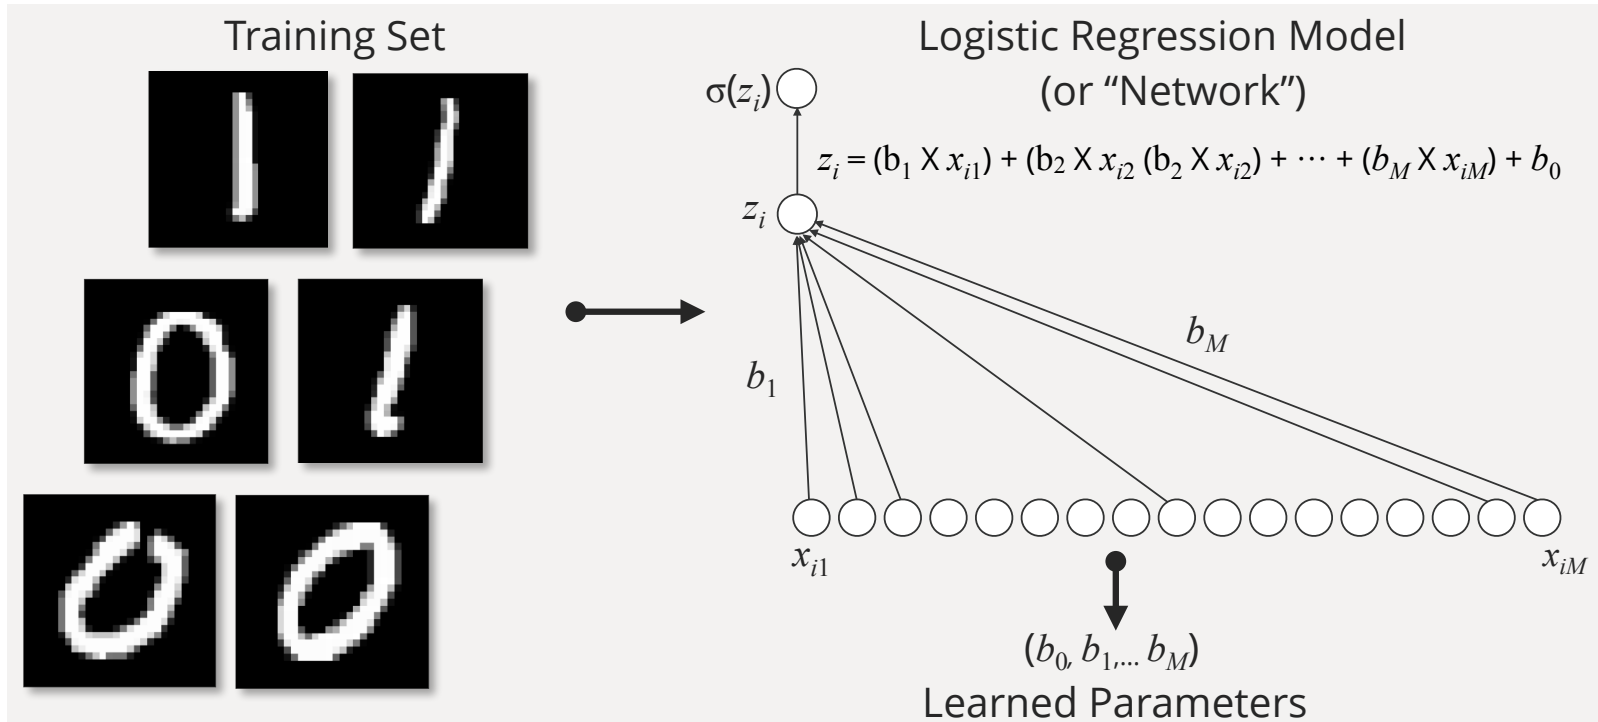


MNIST Dataset of Handwritten Digits (Images)

Yann LeCun (Courant Institute, NYU) and Corinna Cortes (Google Labs, New York) CC-by-SA 3.0

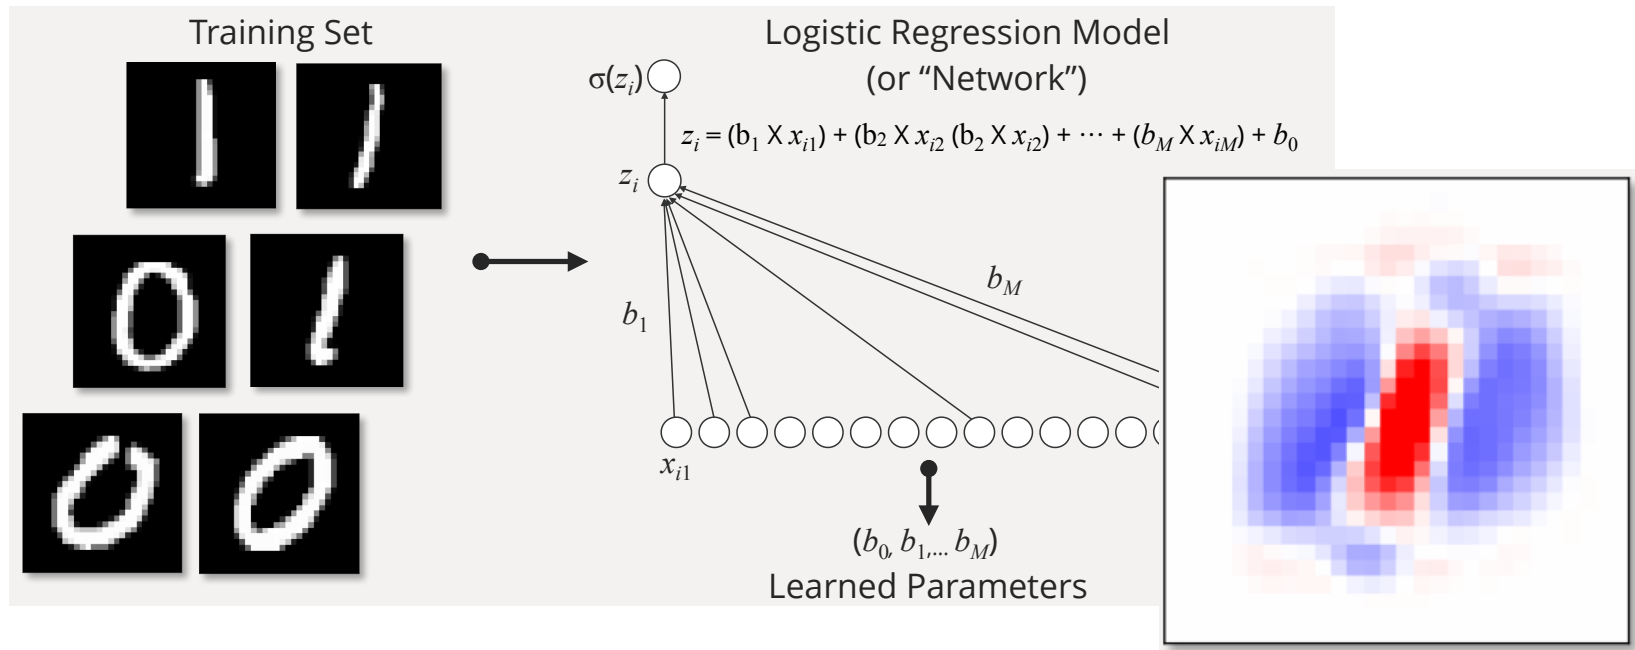
<http://yann.lecun.com/exdb/mnist/>

Apprentissage du MNIST



Chaque position de la matrice est étiquetée avec une valeur négative (0), positive (1) ou rien. Plus on a des 0 ou 1, plus la "case" est fortement marquée (poids de b)

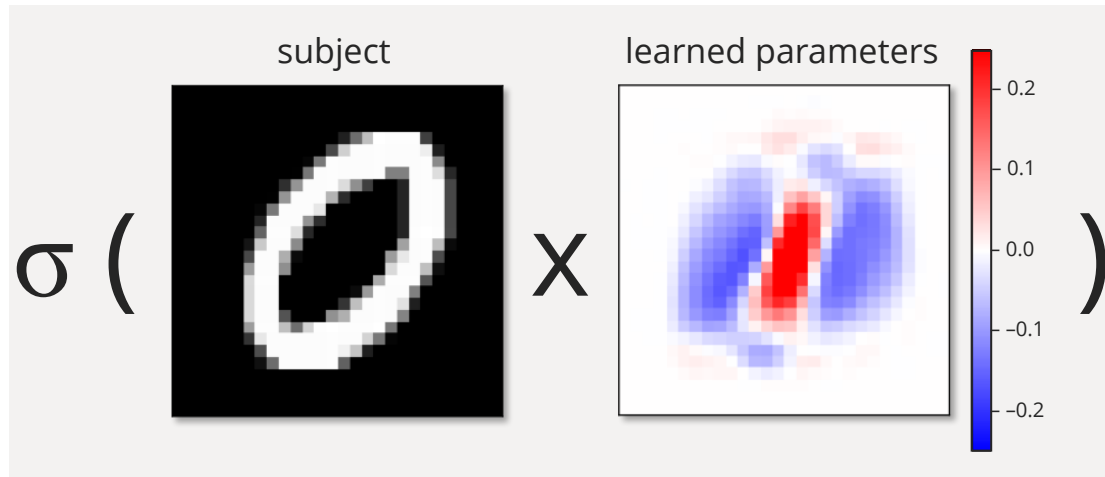
Apprentissage du MNIST



Chaque position de la matrice est étiquetée avec une valeur négative (0), positive (1) ou rien. Plus on a des 0 ou 1, plus la "case" est fortement marquée (poids de b)


Quelle est la probabilité d'être un 1 ?

- Pour un chiffre donné, on compare sa matrice avec la matrice entraînée :



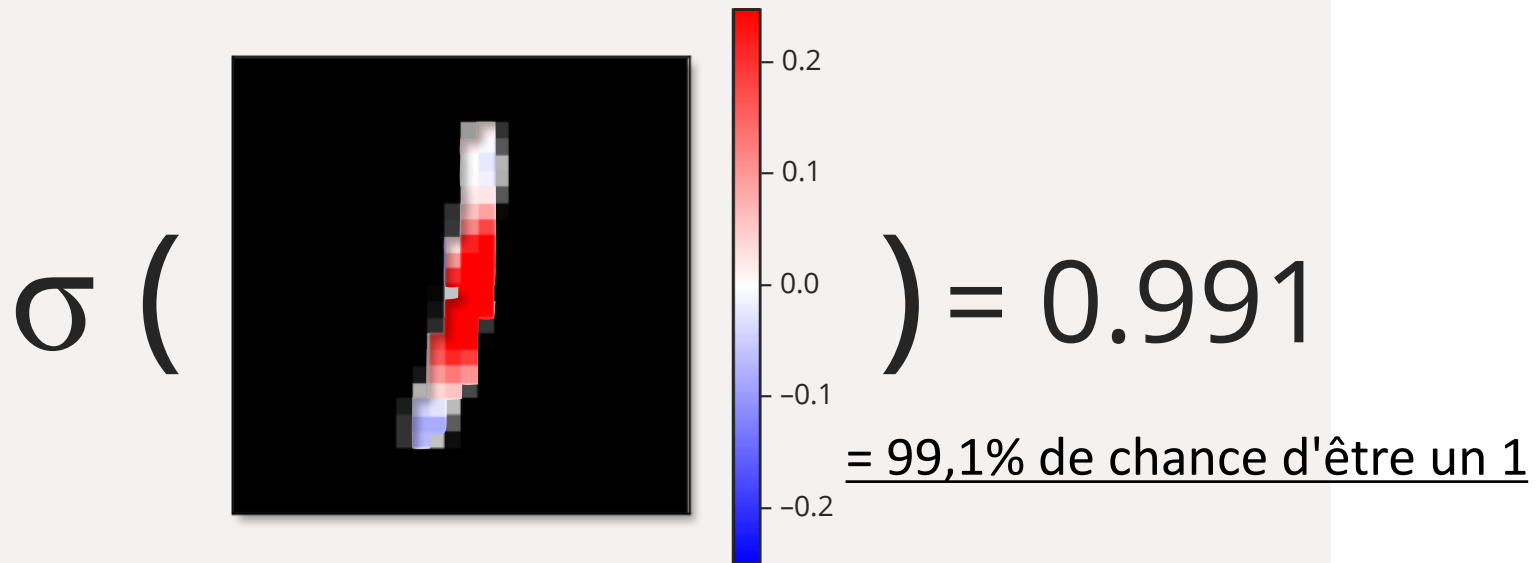
Probabilité d'être un 1

- La "superposition" donne une note pour les parties communes



Probabilité d'un Un

- La "superposition" donne une note pour les parties communes



Interprétation du modèle


$$z_i = (b_1 \times x_{i1}) + (b_2 \times x_{i2}) + \dots + (b_M \times x_{iM}) + b_0$$
$$= b_0 + x_i \odot b$$



examples of class $y = 0$



examples of class $y = 1$




filter b

Une grande correspondance entre le filtre et les données signifie que $p(y_i = 1 | x_i)$ est élevé

Une petite correspondance entre le filtre et les données signifie que $p(y_i = 1 | x_i)$ est bas



Généralisation de la Classification - Plusieurs Classes

- Pour plusieurs chiffres, il faudra créer plusieurs modèles pour dire "**oui**" ou "**non**" sur chaque choix
 - On parle de "dimension de la sortie"
 - On se retrouve avec plusieurs sorties, chacune avec un % exprimé
 - La fonction *softmax()* permet de normaliser les sorties dans un intervalle $[0,1]$




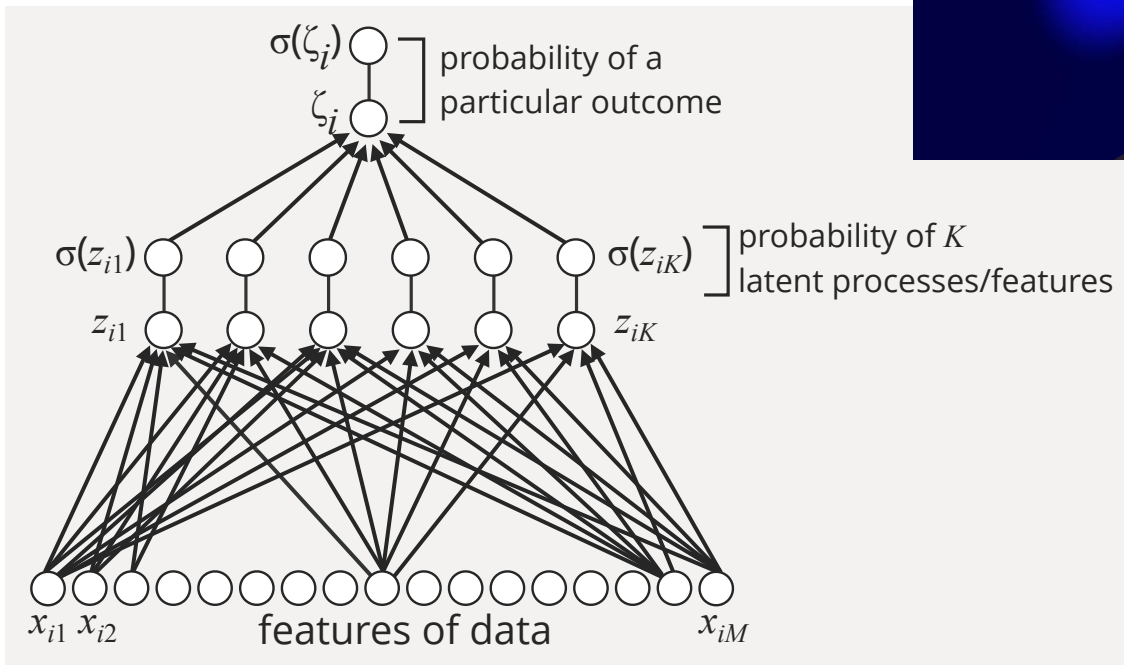
Limitations des réseaux à 1 couche

- Les classifieurs linéaires sont limités dans leurs possibilités
- Souvent on veut classer des données non-linéaires



Réseaux Multi-couche

- Et si on faisait un 2^{ème} niveau de neurones ?





On a une classification sur K features latentes, plutôt que sur M données brutes

Chaque neurone a une vue légèrement différente des autres, et c'est l'union de leurs points de vue que mène au résultat

Exemple : mieux identifier un 4

Filtre unique (shallow)



- pas très précis, adapté juste au cas moyen



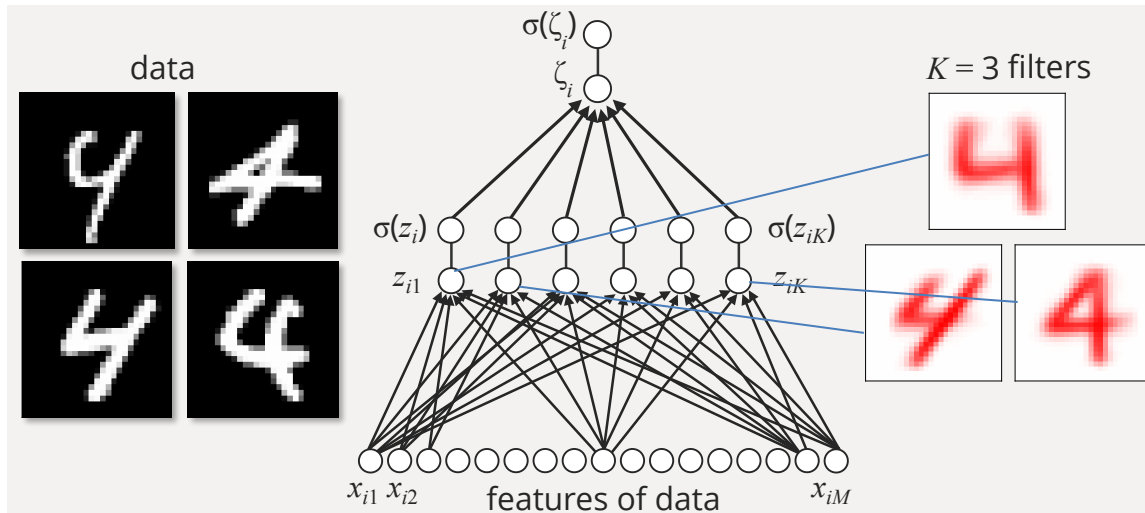
Plusieurs façons d'écrire 4

Plusieurs filtres

- Chacun est spécialisé sur une forme d'écrire 4





Réseau Dense de Neurones



- Dans la pratique, les neurones sont initialisés avec des poids aléatoires
- L'entraînement permet à chacun de regarder les données avec des points de vue différents
- C'est la somme de ces points de vue qui donne une sortie

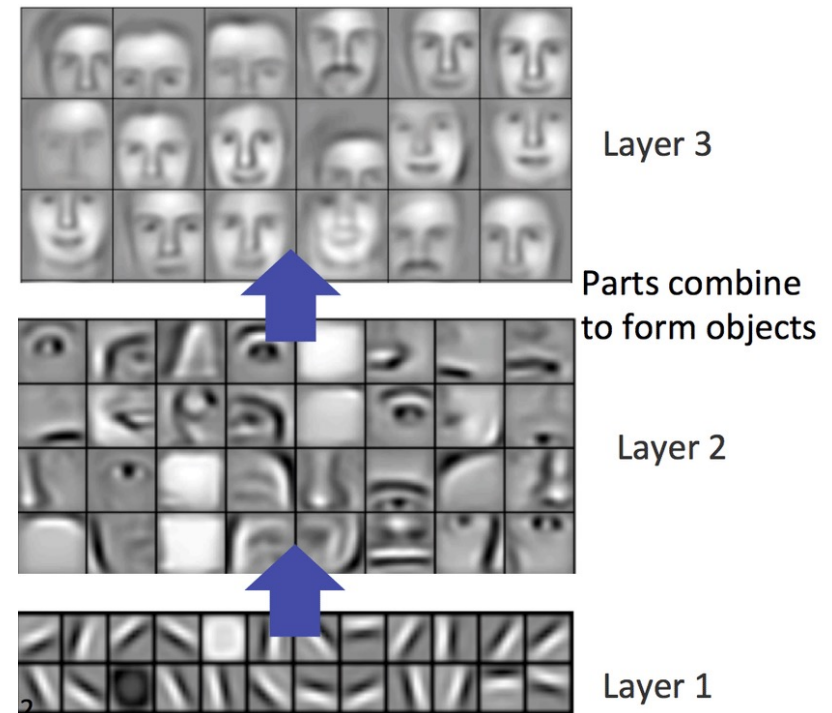
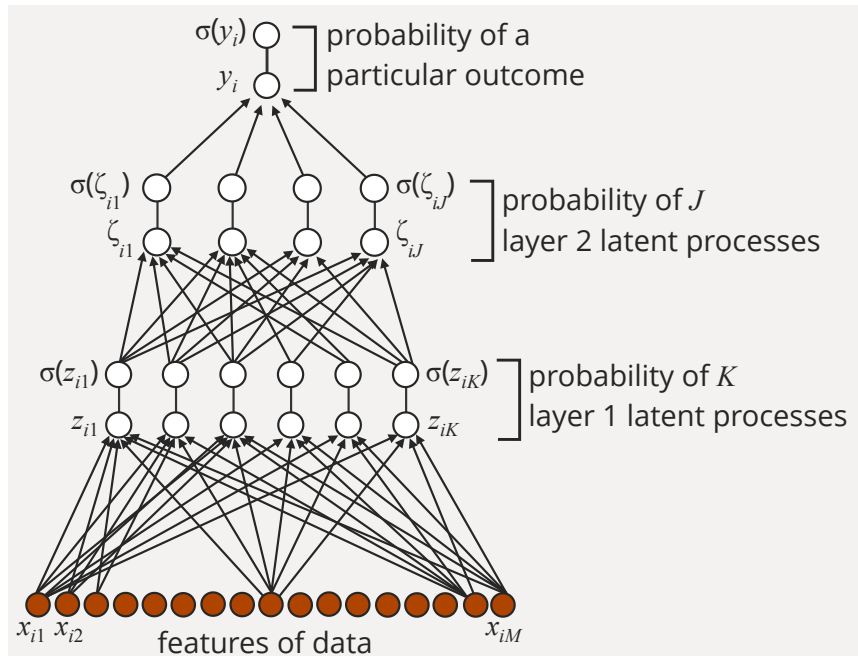
Pourquoi s'arrêter là ?

- Différentes couches peuvent mettre en valeur des features distinctes
 - Plus de couches, plus de "poids" à optimiser
 - Il faut alléger les modèles
 - Les réseaux modernes sont parfois très profonds

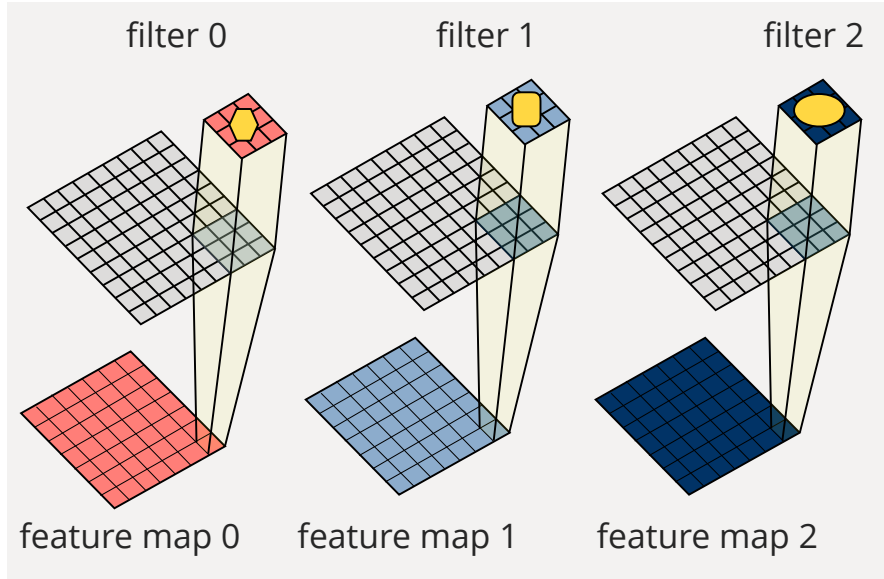


Réseaux Multi-couches avec Convolutions (CNN)

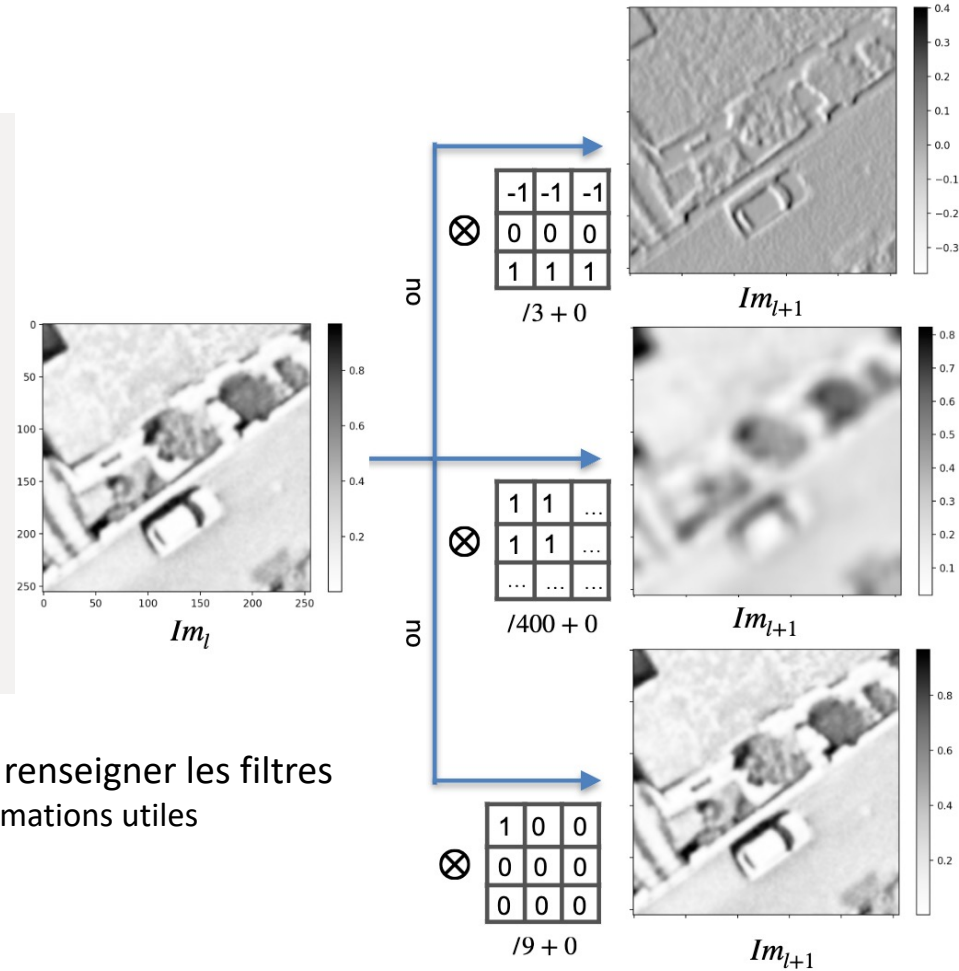
- Plutôt que des filtres complexes, on peut démarrer avec filtres simples (formes de base)
- Leur composition mène à des solutions complexes



Multiples filtres de convolution



- Bonus : la plupart du temps, on n'a pas besoin de renseigner les filtres
 - Génération aléatoire mais qui souvent extrait d'informations utiles



MLP dans Scikit-learn

- Sklearn inclut un module MLPClassifier qui permet de faire des réseaux de neurones

```
# Create a MLP with 2 hidden layers
clf = MLPClassifier(solver='lbfgs', alpha=1e-5,
                    hidden_layer_sizes=(5, 2), random_state=1)

# Train the MLP
clf.fit(X_train_std, y_train)
```

Le choix du nombre et de la forme des couches cachées a un très grand impact sur le résultat

```
: # Apply the trained perceptron on the X data to make predicts for the y test data
y_pred = clf.predict(X_test_std)
# View the accuracy of the model, which is: 1 - (observations predicted wrong / total observations)
print('Accuracy: %.2f' % accuracy_score(y_test, y_pred))
```

Accuracy: 0.93

Aller plus loin

- Les réseaux de neurones sont une solution avec beaucoup de potentiel
 - Pas toujours meilleure que les autres méthodes
 - Mais très efficace pour de images (à cause des convolutions)
- Scikit Learn n'est pas optimisé pour les réseaux de neurones
 - Ne supporte pas l'accélération sur GPU
- Certaines bibliothèques telles que **Keras** vous permettent de programmer en Tensorflow ou Pytorch avec une syntaxe proche de celle de Sklearn

Hands-on

- Récupérer l'exercice "IntroNN_avec_Sklearn" sur le bureau virtuel